

ASVD格式: $A = (\text{正交矩阵}) \Lambda (\text{对角矩阵}) \times (\text{正交矩阵})$

379

7.2B 证明 $\sigma_1 \geq |\lambda|_{\max}$ 。最大的奇异值支配所有的特征值。

解 从 $A = U\Sigma V^T$ 开始, 记得左乘一个正交矩阵不会改变长度: $\|Qx\| = \|x\|$, 因为 $\|Qx\|^2 = x^T Q^T Q x = x^T x = \|x\|^2$ 。这个性质应用到 $Q = U$ 与 $Q = V^T$, 在中间的是对角矩阵 Σ :

$$\|Ax\| = \|U\Sigma V^T x\| = \|\Sigma V^T x\| \leq \sigma_1 \|V^T x\| \leq \sigma_1 \|x\| \quad (14)$$

特征向量有 $\|Ax\| = |\lambda| \|x\|$, 所以(14)说明 $|\lambda| \|x\| \leq \sigma_1 \|x\|$, 则 $|\lambda| \leq \sigma_1$ 。

同样应用到单位向量 $x = (1, 0, \dots, 0)$, 现在 Ax 是 A 的第一列, 依据(14), 这个列的长度 $\leq \sigma_1$, 每个单元必须有 $|a_{ij}| \leq \sigma_1$ 。

方程式(14)再次展示 $\|Ax\| / \|x\|$ 的极大值等于 σ_1 。

段落 11.2 会说明在求解 $Ax = b$ 时, 比值 $\sigma_{\max}/\sigma_{\min}$ 掌管舍去误差。如果这个“条件数字”太大, MATLAB 会警告你, 这个 x 就不可靠。

注意: 数学界与工业界默认 $6170 \dots 6170$ 故选特征值也最好从大到小选取, 本人这是反例第 u_1, u_2 顺序变化, 请注意!!!

问题集 7.2

$$AA^T = (U\Sigma V^T)^T (U\Sigma V^T) = V^T \Sigma^T U^T U \Sigma V = V \Sigma^2 V^T$$

1 求出下列矩阵的特征值, 再从 $A^T A$ 求出奇异值:

$$A^T A = \begin{bmatrix} 0 & 0 \\ 4 & 0 \end{bmatrix} \begin{bmatrix} 0 & 4 \\ 0 & 0 \end{bmatrix} = \begin{bmatrix} 0 & 0 \\ 0 & 16 \end{bmatrix}$$

$$A = \begin{bmatrix} 0 & 4 \\ 0 & 0 \end{bmatrix}$$

$$A = \begin{bmatrix} 0 & 4 \\ 1 & 0 \end{bmatrix}$$

对每个 A , 从 $A^T A$ 的特征向量创建 V , 从 AA^T 的特征向量创建 U , 检验 $A = U\Sigma V^T$ 。

求出 A 与 V 与 Σ 与 $u_i = Av_i/\sigma_i$ 以及全部的 SVD:

$$A = \begin{bmatrix} 2 & 2 \\ -1 & 1 \end{bmatrix} = U\Sigma V^T$$

$$A^T A = \begin{bmatrix} 2 & 2 \\ 2 & 2 \end{bmatrix} \begin{bmatrix} 2 & 2 \\ 2 & 2 \end{bmatrix} = \begin{bmatrix} 8 & 8 \\ 8 & 8 \end{bmatrix}$$

3 在问题 2, 展示 AA^T 是对角, 它的特征向量 u_1, u_2 是 $\sqrt{2}, \sqrt{2}$ 。A 的行是正交但是他们不是单位向量, 所以 A 的列不是正交。

4 计算 $A^T A$ 与 AA^T 以及他们对应 U 与 V 的特征值及单位特征向量。

$$\text{矩形矩阵 } A = \begin{bmatrix} 1 & 1 & 0 \\ 0 & 1 & 1 \end{bmatrix}$$

检验 $AV = U\Sigma$ (这个决定 U 中的 $\pm$ 号), Σ 有与 A 相同的形状: $\begin{bmatrix} 2 & 3 \end{bmatrix}$ 。

(a) $A = \begin{bmatrix} 1 & 1 \\ 3 & 3 \end{bmatrix}$ 的行空间是一个 1-维, 求出在行空间的 v_1 与在列空间的 u_1 。

$(A^T) Av = 6u_1$, 行空间: 由 $[1, 1]$ 展开, $v_1 = \begin{bmatrix} 1 \\ 1 \end{bmatrix}$
 $(A) Au = 6v_1$, 列空间: 由 $[3]$ 展开, $u_1 = \begin{bmatrix} 3 \\ 3 \end{bmatrix}$

σ_1 为何? 为什么没有 σ_2 。列空间: 由 $[3]$ 展开, $u_1 = \begin{bmatrix} 3 \\ 3 \end{bmatrix}$

奇异值 $\lambda_1 = 3\sqrt{2}$, $\lambda_2 = 0$

奇异值 $\lambda_1 = 3\sqrt{2}$, $\lambda_2 = 0$

$$\det(A - \lambda I) = \det \begin{bmatrix} -\lambda & 4 \\ 0 & -\lambda \end{bmatrix} = \lambda^2 = 0$$

$$\lambda = 0$$

$$(A - 0I)u = 0$$

$$\begin{bmatrix} 0 & 4 \\ 0 & 0 \end{bmatrix} \begin{bmatrix} u_1 \\ u_2 \end{bmatrix} = \begin{bmatrix} 0 \\ 0 \end{bmatrix}$$

$$u_2 = 0$$

$$u_1 = \begin{bmatrix} 1 \\ 0 \end{bmatrix}$$

$$A^T A = \begin{bmatrix} 1 & 1 \\ 0 & 1 \end{bmatrix} \begin{bmatrix} 1 & 1 \\ 0 & 1 \end{bmatrix} = \begin{bmatrix} 2 & 1 \\ 0 & 1 \end{bmatrix}$$

$$AA^T = \begin{bmatrix} 1 & 1 \\ 0 & 1 \end{bmatrix} \begin{bmatrix} 1 & 1 \\ 0 & 1 \end{bmatrix} = \begin{bmatrix} 2 & 1 \\ 0 & 1 \end{bmatrix}$$

$$\det(AA^T - \lambda I) = (2 - \lambda)(1 - \lambda) = 0$$

$$\lambda_1 = 2, \lambda_2 = 1$$

$$(AA^T - 2I)u = 0$$

$$\begin{bmatrix} 0 & 1 \\ 0 & 0 \end{bmatrix} \begin{bmatrix} u_1 \\ u_2 \end{bmatrix} = \begin{bmatrix} 0 \\ 0 \end{bmatrix}$$

$$u_2 = 0$$

$$u_1 = \begin{bmatrix} 1 \\ 0 \end{bmatrix}$$

$$\det(A - \lambda I) = \det \begin{bmatrix} -\lambda & 4 \\ 1 & -\lambda \end{bmatrix} = \lambda^2 - 4 = (\lambda - 2)(\lambda + 2)$$

$$\lambda_1 = 2, \lambda_2 = -2$$

$$A^T A = \begin{bmatrix} 0 & 1 \\ 4 & 0 \end{bmatrix} \begin{bmatrix} 0 & 1 \\ 4 & 0 \end{bmatrix} = \begin{bmatrix} 0 & 0 \\ 0 & 16 \end{bmatrix}$$

$$AA^T = \begin{bmatrix} 0 & 1 \\ 4 & 0 \end{bmatrix} \begin{bmatrix} 0 & 1 \\ 4 & 0 \end{bmatrix} = \begin{bmatrix} 16 & 0 \\ 0 & 0 \end{bmatrix}$$

$$U\Sigma V^T = \begin{bmatrix} 0 & 1 \\ 1 & 0 \end{bmatrix} \begin{bmatrix} 0 & 1 \\ 4 & 0 \end{bmatrix} \begin{bmatrix} 0 & 1 \\ 1 & 0 \end{bmatrix} = \begin{bmatrix} 0 & 1 \\ 4 & 0 \end{bmatrix} = A$$

$$(A - 2I)v = 0$$

$$\begin{bmatrix} -2 & 4 \\ 1 & -2 \end{bmatrix} \begin{bmatrix} v_1 \\ v_2 \end{bmatrix} = \begin{bmatrix} 0 \\ 0 \end{bmatrix}$$

$$v_2 = 2v_1$$

$$v_1 = \begin{bmatrix} 1 \\ 2 \end{bmatrix}$$

$$(A + 2I)u = 0$$

$$\begin{bmatrix} 2 & 4 \\ 1 & 2 \end{bmatrix} \begin{bmatrix} u_1 \\ u_2 \end{bmatrix} = \begin{bmatrix} 0 \\ 0 \end{bmatrix}$$

$$u_2 = -\frac{1}{2}u_1$$

$$u_1 = \begin{bmatrix} 2 \\ 1 \end{bmatrix}$$

$$(b) A = \frac{1}{\sqrt{2}} \begin{bmatrix} \frac{1}{\sqrt{2}} & \frac{1}{\sqrt{2}} \\ \frac{1}{\sqrt{2}} & -\frac{1}{\sqrt{2}} \end{bmatrix} = \frac{1}{2} \begin{bmatrix} 1 & 1 \\ 1 & -1 \end{bmatrix} = \frac{1}{2} A = A$$

左重全的 $N(A)$ 的基

$6. A^T A = (U \Sigma V^T)^T (U \Sigma V^T) = V^T \Sigma^T U^T U \Sigma V^T = V^T \Sigma^T \Sigma V^T$ AFA的特征值是 $\Sigma^T \Sigma$ 的对角元
 $A A^T = (U \Sigma V^T) (U \Sigma V^T)^T = (U \Sigma V^T) (V \Sigma^T U^T) = U \Sigma (V^T V) \Sigma^T U^T = U \Sigma \Sigma^T U^T$ 元为
 $U, V \in \mathbb{R}^n, V V^T = I$ AFA的特征值是 $\Sigma \Sigma^T$ 的对角元
它们的非零对角元

都是A的非法
整值。而6

$$f_{\text{max}} = 5$$

知不足[1]

(b) 选择 V 与 U 中的 v_2 与 u_2 , 则 $A = U\Sigma V^T = u_1\sigma_1v_1^T$ (只有一项)。

【原文是 U and V ，换过来比较合适】

把 A 与 A^T 的 SVD 代入, 展示 $A^T A$ 的特征值在 $\Sigma^T \Sigma$ 中, AA^T 的特征值在 $\Sigma \Sigma^T$ 中。对 角矩阵 $\Sigma^T \Sigma$ 与 $\Sigma \Sigma^T$ 有相同的非零数字, 我们再次看到 $A^T A$ 与 AA^T 有相同非零特征值。

若 $(A^T A)v = \sigma^2 v$, 左乘 A , 移动括号得到 $(AA^T)Av = \sigma^2(Av)$. 若 v 是 $A^T A$ 的特征向量, 则 Av 是 AA^T 的特征向量。 $A(A^T Av) = A(\sigma^2 v) \quad (A^T A)v = \sigma^2 v$

求出 $A^T A$ 的特征值与单位特征向量 v_1 与 v_2 , 然后求出 $u_1 = Av_1/\sigma_1$

$$A = \begin{bmatrix} 1 & 2 \\ 3 & 6 \end{bmatrix}$$

$$A^T A = \begin{bmatrix} 10 & 20 \\ 20 & 40 \end{bmatrix}$$

$$AA^T = \begin{bmatrix} 5 & 15 \\ 15 & 45 \end{bmatrix}$$

验证 u_1 是 AA^T 的单位特征向量, 计算矩阵 U, Σ, V .

SVD

$$A = \begin{bmatrix} 1 & 2 \\ 3 & 6 \end{bmatrix} = [u_1 \ u_2] \begin{bmatrix} \sigma_1 & 0 \\ 0 & \sigma_2 \end{bmatrix} [v_1 \ v_2]^T$$

$AA^T = \begin{bmatrix} 5 & 15 \\ 15 & 45 \end{bmatrix}$

写下这个 A 的 4 个基础子空间的正交单位基底。

(a) 为什么 A^1A 的迹等于所有的 a_{ij}^2 的总和? 在范例 3 它是 50。

(b) 对于每个秩 1 矩阵, 为什么 σ_1^2 等于所有的 a_{ij}^2 的总和?

求出 $A^T A$ 与 AA^T 的特征值与单位特征向量, 使得每个 $A\mathbf{v} = \sigma\mathbf{u}$. 然后对 A 奇异值分解并且验证 A 等于 $U\Sigma V^T$.
 1. A 是实对称阵, 可由特征值分解直接推导 SVD. $G_1 = \phi, G_2 = \phi$. 单位特征向量 $\mathbf{q}_1 = \frac{1}{\sqrt{2}} \begin{bmatrix} 1 \\ 1 \end{bmatrix}$

$(A - \lambda I) = \begin{pmatrix} 4-\lambda & -2 \\ 1 & 1-\lambda \end{pmatrix}$ 费氏矩阵 $A = \begin{pmatrix} 4 & -2 \\ 1 & 1 \end{pmatrix}$
 $= \lambda^2 - \lambda - 1 = 0$ $\lambda = \frac{1 \pm \sqrt{5}}{2}$ (线为0) $\lambda_1 = \frac{1+\sqrt{5}}{2}$ (线为0) $\lambda_2 = \frac{1-\sqrt{5}}{2}$
 使用 MATLAB 展示 eigshow 的 SVD 部分求出 v 's 的图形。
 若 $A = U\Sigma V^T$ 是方形可逆矩阵, 则 $A^{-1} = (UV^T)^{-1} = V(\Sigma^{-1})U^T$ 检查 $A^{-1}A$ 。
 展示了 A^{-1} 的奇异值是 $1/\sigma_i$ 。
 注解: A^{-1} 的最大奇异值是 $1/\sigma_{\min}(A)$, 最大的特征值 $|\lambda(A^{-1})|_{\max}$ 是 $1/|\lambda(A)|_{\min}$ 。

则方程式(14)说明了 $\sigma_{\min}(A) \leq |\lambda(A^{-1})|_{\min}$ 。

无因管理

假设 $u_1, \dots, u_n$ 与 $v_1, \dots, v_n$ 是 $\mathbb{R}^n$ 的正交单位基底, 创建矩阵 $A = U\Sigma V^T$. 把 v_i 变换成 u_i 得到 $Av_1 = u_1, \dots, Av_n = u_n$. 14. $A[v_1 \ v_2 \ \dots \ v_n][u_1 \ u_2 \ \dots \ u_n] \Rightarrow AV = U$

创建秩 1 矩阵使得 $Av = 12u$, 其中 $v = \frac{1}{2}(1, 1, 1, 1)$ 与 $u = \frac{1}{3}(2, 2, 1)$ 。它的奇异值是 $\sigma = 12$ 。

假设 A 有非交列 $w_1, w_2, \dots, w_n$, 长度分别是 $\sigma_1, \sigma_2, \dots, \sigma_n$. SVD 中的 U, Σ 满足:

$$A^T A = \begin{bmatrix} w_1 & w_2 & \dots & w_n \\ w_1^T & w_2^T & \dots & w_n^T \end{bmatrix} = \begin{bmatrix} \sigma_1^2 & & & \\ & \sigma_2^2 & & \\ & & \ddots & \\ & & & \sigma_n^2 \end{bmatrix} = \begin{bmatrix} \sigma_1 & & & \\ & \sigma_2 & & \\ & & \ddots & \\ & & & \sigma_n \end{bmatrix} \begin{bmatrix} w_1 & w_2 & \dots & w_n \\ w_1^T & w_2^T & \dots & w_n^T \end{bmatrix}$$

假设 A 是 2×2 对称矩阵，它的单位特征向量是 u_1 与 u_2 。如果它的特征值 $\lambda_1 = 3$ 与 $\lambda_2 = -2$ ，则 SVD 中的 U, Σ, V^T 为何？

$A = \begin{bmatrix} 3 & 0 \\ 0 & 2 \end{bmatrix}$ 设 $\tilde{u}_1 = u_1, \tilde{v}_1 = u_1$
 正向量分解) 网址: linear.necitycitys.org 邮箱: 876152660@qq.com
 $\tilde{u}_2 = u_2, \tilde{v}_2 = -u_2$
 $U = [u_1, u_2] \quad V = \begin{bmatrix} u_1^T \\ -u_2^T \end{bmatrix}$
 $\Sigma = \begin{bmatrix} 3 & 0 \\ 0 & 2 \end{bmatrix}$ 解: $A = 3u_1u_1^T - 2u_2u_2^T$
 $\tilde{u}_1 = u_1, \tilde{v}_1 = u_1$
 $\tilde{u}_2 = u_2, \tilde{v}_2 = -u_2$
 求: $A = 6\tilde{u}_1\tilde{v}_1^T + 6\tilde{u}_2\tilde{v}_2^T = 3\tilde{u}_1\tilde{v}_1^T + 2\tilde{u}_2\tilde{v}_2^T$

征值是 λ_1 都是 0.

$$Z = \begin{bmatrix} b_1 & & \\ & b_2 & \\ & & \ddots \\ & & & b_n \end{bmatrix}$$

$$V = \begin{bmatrix} 1 & & \\ & \ddots & \\ & & 1 \end{bmatrix} \quad u_i \rightarrow \frac{u_i}{b_i}$$

$$U = [u_1 \dots u_n] = \begin{bmatrix} \frac{u_1}{b_1} & \frac{u_2}{b_2} & \dots & \frac{u_n}{b_n} \end{bmatrix}$$

(1/18 2/3 列) 2/4

19. 一个矩阵是奇异的
有一个特征值为0
根据秩逼近定理, 令 $\epsilon_2 = 0$

18. $R = U_R Z_R V_R^T$
 $A = QR = (QU_R)Z_R V_R^T$
 $(QU_R)^T (QU_R) = U_R^T Q^T Q U_R = U_R^T U_R = I$

$Q U_R$ 是正交矩阵
 $U_A = Q U_R, Z_A = Z_R, V_A = V_R^T$
乘以 Q 后, 在奇异向量发生变化, 输出空间的最终朝向改变, 而拉伸程度 (正) 与输入空间主方向 (V) 不会改变

$A_0 = [u_1, u_2] \begin{bmatrix} \sigma_1 & 0 \\ 0 & \sigma_2 \end{bmatrix} [v_1^T, v_2^T]^T$
 $= [u_1, u_2] \begin{bmatrix} u_1^T \\ u_2^T \end{bmatrix} \begin{bmatrix} v_1^T \\ v_2^T \end{bmatrix}$
 $= U \Sigma V^T$

19 假设 A 是可逆 ($\sigma_1 > \sigma_2 > 0$), 对 A 进行尽可能小的改变得到奇异矩阵 A_0 . 提示: U 与 V 不变.

从 $A = [u_1 \ u_2] \begin{bmatrix} \sigma_1 & \\ & \sigma_2 \end{bmatrix} [v_1 \ v_2]^T$ 求最接近的 A_0

20. $A^T A = \begin{bmatrix} 1 & 100 \\ 0 & 1 \end{bmatrix} \begin{bmatrix} 1 & 0 \\ 100 & 1 \end{bmatrix} = \begin{bmatrix} 10001 & 100 \\ 100 & 1 \end{bmatrix}$
 $\lambda_1 + \lambda_2 = 10001 + 1 = 10002$
 $\det(A^T A) = 10001 - 10000 = 1 = \lambda_1 \lambda_2$
 $\lambda_1^2 - 10002\lambda_1 + 1 = 0$
 $\lambda_1 \approx 10001, \lambda_2 \approx 1$
 $\sigma_1 = \sqrt{\lambda_1} \approx 10001, \sigma_2 = \sqrt{\lambda_2} \approx 1$

21. $U(Z+I)V^T$
 $= UZV^T + UVV^T$
 $= A + UVV^T$
若要 $A + UVV^T = A + I$
只需 $UVV^T = I$

20 从指令 `svd(A)` 或是手算, 求出 A 的奇异值.

$A = \begin{bmatrix} 1 & 0 \\ 100 & \bullet \end{bmatrix}$ 为什么这个矩阵有 $\sigma_2 = 1/\sigma_1$?

22. V 为正交矩阵
 $\therefore V^T = V^{-1}$
 $UVV^T = UVV^T = I$
 $U = V$

21 为什么 $A + I$ 的 SVD 直接使用 $\Sigma + I$?
22 若 $A = U\Sigma V^T$ 则 $Q_1 A Q_2^T = (Q_1 U)^T \Sigma (Q_2 V)^T$. 为什么任意的正交矩阵 Q_1 与 Q_2 会使得 $Q_1 U =$ 正交矩阵且 $Q_2 V =$ 正交矩阵? 然后 Σ 在奇异值中看不到变化: SVD 奇异值是唯一的, 故 $Q_1 U, Q_2 V$ 是正交矩阵. 中间对称矩阵像旧矩阵 Σ 故新矩阵的奇异值矩阵 Σ 不变.

23 若 Q 是正交矩阵, 为什么它的所有奇异值都是 1?

23 若 Q 是正交矩阵, 为什么它的所有奇异值都是 1?

23. Q 是正交矩阵, $Q^T Q = I$
 $\lambda_1^2 = 1, \lambda_2^2 = 1$
 $\lambda_1 = 1, \lambda_2 = -1$
 $\sigma_1 = \sqrt{\lambda_1^2} = 1, \sigma_2 = \sqrt{\lambda_2^2} = 1$

24. (a)
二次项形式: $a_1 x^2 + 2a_2 x_1 x_2 + a_3 x_2^2$
 $S = \begin{bmatrix} a_1 & a_2 \\ a_2 & a_3 \end{bmatrix} = \begin{bmatrix} 3 & 1 \\ 1 & 3 \end{bmatrix}$
 $\det(S - \lambda I) = (3-\lambda)^2 - 1 = \lambda^2 - 6\lambda + 8 = (\lambda-4)(\lambda-2)$
 $\lambda_1 = 4, \lambda_2 = 2$
极大值为 4, $S = \begin{bmatrix} 3 & 1 \\ 1 & 3 \end{bmatrix}$
(b) 令 $x = \begin{bmatrix} x_1 \\ x_2 \end{bmatrix}, A = \begin{bmatrix} 1 & 4 \\ 4 & 1 \end{bmatrix}$
 $Ax = \begin{bmatrix} 1 & 4 \\ 4 & 1 \end{bmatrix} \begin{bmatrix} x_1 \\ x_2 \end{bmatrix} = \lambda \begin{bmatrix} x_1 \\ x_2 \end{bmatrix}$
 $A^T A = \begin{bmatrix} 1 & 4 \\ 4 & 1 \end{bmatrix} \begin{bmatrix} 1 & 4 \\ 4 & 1 \end{bmatrix} = \begin{bmatrix} 17 & 8 \\ 8 & 17 \end{bmatrix}$
 $\det(A^T A - \lambda I) = (\lambda-17)(\lambda-1) = \lambda^2 - 18\lambda + 17 = (\lambda-17)(\lambda-1)$
 $\lambda_1 = 17, \lambda_2 = 1$
远是 A 的特征向量吗?

(a) 求出 $\frac{x^T S x}{x^T x} = \frac{3x_1^2 + 2x_1 x_2 + 3x_2^2}{x_1^2 + x_2^2}$ 的极大值, 矩阵 S 为何?
(b) 求出 $\frac{\|Ax\|^2}{x^T x}$ 的极大值, 这个 $\frac{\|Ax\|^2}{x^T x}$ 中的矩阵 A 为何?

25. (b) $\lambda_1 = 17, \lambda_2 = 1$
最大值 17 $A = \begin{bmatrix} 1 & 4 \\ 4 & 1 \end{bmatrix}$

25 比值 $\frac{x^T S x}{x^T x}$ 与 $\frac{\|Ax\|^2}{x^T x}$ 的极小值为何? 我们应该选择 S 的哪一个特征向量? x 永

25. 根据瑞利商定理, $\frac{x^T S x}{x^T x}$ 取值等于对称阵 S 的最小特征值 $\lambda_{\min}$. 取值等于对称阵 $A^T A$ 的最小特征值 $\lambda_{\min}$ (A 的左右奇异值 $\sigma_{\min}$). λ 是 $A^T A$ 的特征值, 而不是 A 的, A 都是方阵.

26. $V = [v_1 \ v_2], U = [u_1 \ u_2]$
 $U = [u_1 \ u_2], u_1 = \begin{bmatrix} \cos \theta \\ \sin \theta \end{bmatrix}, u_2 = \begin{bmatrix} -\sin \theta \\ \cos \theta \end{bmatrix}$
 $v_1 u_1 = 2u_1 = \begin{bmatrix} 2\cos \theta \\ 2\sin \theta \end{bmatrix}$
 $v_2 u_2 = u_2 = \begin{bmatrix} -\sin \theta \\ \cos \theta \end{bmatrix}$
(见下面)

26 每个矩阵 $A = U\Sigma V^T$ 使得圆变成椭圆. $AV = U\Sigma$ 说明圆的半径向量 v_1 与 v_2 来到椭圆的半轴 (semi-axes) $\sigma_1 u_1$ 与 $\sigma_2 u_2$. 画出这个圆以及 $\theta = 30^\circ$ 的椭圆:

$V = \begin{bmatrix} 0 & 1 \\ 1 & 0 \end{bmatrix}, U = \begin{bmatrix} \cos \theta & -\sin \theta \\ \sin \theta & \cos \theta \end{bmatrix}, \Sigma = \begin{bmatrix} 2 & 0 \\ 0 & 1 \end{bmatrix}$
 $V^T = V = \begin{bmatrix} 0 & 1 \\ 1 & 0 \end{bmatrix}$

对称阵 S 会把 $\sigma_1 = 2$ 新方向轴放大 2 倍, y 轴方向保持原 $\sigma_2 = 1$

段落 7.4 会从关于 2×2 矩阵的一个重要的 SVD 图形开始:

$A =$ (旋转) (拉伸) (旋转), 且对称 $S =$ (旋转) (拉伸) (旋转回去)

二维旋转矩阵: $\theta = 30^\circ, U = \begin{bmatrix} \frac{\sqrt{3}}{2} & -\frac{1}{2} \\ \frac{1}{2} & \frac{\sqrt{3}}{2} \end{bmatrix}$
拉伸: $\sigma_1 = 2, \sigma_2 = 1$ 方向 $u_1 = (\frac{\sqrt{3}}{2}, \frac{1}{2})$
拉伸: $\sigma_1 = 1, \sigma_2 = 1$ 方向 $u_2 = (-\frac{1}{2}, \frac{\sqrt{3}}{2})$

27. 假设 A 的列在 $\mathbb{R}^n$ 的行空间. 假设 $c_1, \dots, c_r$ 与 $b_1, \dots, b_r$ 是这两个空间的基底. 然后分别进入 C 与 B 的列, 我们的目的是展示 A 有下列形式:
矩阵 A 的列也是列空间的基底
矩阵 B 的列也是列空间的基底

27 这个问题在寻找所有的矩阵 A , 其中 A 给定一个在 $\mathbb{R}^m$ 的列空间以及给定一个在 $\mathbb{R}^n$ 的行空间. 假设 $c_1, \dots, c_r$ 与 $b_1, \dots, b_r$ 是这两个空间的基底. 然后分别进入 C 与 B 的列, 我们的目的是展示 A 有下列形式:

$A = CMB^T$, 其中 M 是 $r \times r$ 的可逆矩阵. 提示: 从 $A = U\Sigma V^T$ 开始.

U 与 V 的前 r 个列必须借由可逆矩阵与 C 及 B 产生关联, 因为他们包含对应相同列空间 (在 U) 与行空间 (在 V) 的基底. &

U 的 r 个列向量构成 A 的列空间一组标准正交基
 V 的 r 个列向量构成 A 的行空间一组标准正交基
 Z 是 $r \times r$ 的对角矩阵 (可逆)


$\therefore$ 可逆矩阵 P , s.t. $U_r = CP$
 $\therefore$ 可逆矩阵 Q , s.t. $V_r = BQ$

$A = U_r \Sigma_r V_r^T = CP \Sigma_r (BQ)^T = CP \Sigma_r Q^T B^T$ 令 $M = P \Sigma_r Q^T$, P 可逆, Q 可逆, Σ_r 也是, 且都是 $r \times r$ 的
可逆矩阵乘积依旧是可逆矩阵, 故 M 是 $r \times r$ 的可逆矩阵

26. $A = U \Sigma V^T = \begin{bmatrix} \cos 30^\circ & -\sin 30^\circ \\ \sin 30^\circ & \cos 30^\circ \end{bmatrix} \begin{bmatrix} 2 & 0 \\ 0 & 1 \end{bmatrix} \begin{bmatrix} \cos 30^\circ & \sin 30^\circ \\ -\sin 30^\circ & \cos 30^\circ \end{bmatrix} = \begin{bmatrix} 2\cos^2 30^\circ & 2\cos 30^\circ \sin 30^\circ \\ 2\sin \cos 30^\circ & 2\sin^2 30^\circ + 1 \end{bmatrix} = \begin{bmatrix} 3 & 1 \\ 1 & 2 \end{bmatrix}$

$Av_1 = A \begin{bmatrix} 1 \\ 0 \end{bmatrix} = \begin{bmatrix} 3 \\ 1 \end{bmatrix} = 3u_1$ 第1特征 $v_1 = \begin{bmatrix} 1 \\ 0 \end{bmatrix}$, 沿 x 轴半径变为长度为3, 与 x 轴成 30° 角, 椭圆半轴

$Av_2 = A \begin{bmatrix} 0 \\ 1 \end{bmatrix} = \begin{bmatrix} 1 \\ 2 \end{bmatrix} = 2u_2$ 第2特征 $v_2 = \begin{bmatrix} 0 \\ 1 \end{bmatrix}$, 沿 y 轴半径变为长度为2, 和 x 轴垂直, 椭圆半轴



11题(详细过程): 7.3 主要分量分析(SVD 做 PCA)

$AA^T = \begin{bmatrix} 1 & 1 \\ 1 & 2 \end{bmatrix} \begin{bmatrix} 1 & 1 \\ 0 & 1 \end{bmatrix} = \begin{bmatrix} 2 & 1 \\ 1 & 2 \end{bmatrix}$

$\lambda^2 - 3\lambda + 1 = 0$
 $\lambda = \frac{3 \pm \sqrt{5}}{2}$
 $\lambda_1 = \phi^2$
 $\lambda_2 = 1/\phi^2$
 $b_1 = \phi$
 $b_2 = 1/\phi$

$v_1 = \frac{1}{\sqrt{2}} \begin{bmatrix} 1 \\ 1 \end{bmatrix}$
 $v_2 = \frac{1}{\sqrt{2}} \begin{bmatrix} 1 \\ -1 \end{bmatrix}$
 $U = [u_1 u_2]$
 $A = U \Sigma V^T$
 $\begin{bmatrix} 1 & 1 \\ 0 & 1 \end{bmatrix} = \begin{bmatrix} \frac{1}{\sqrt{2}} & \frac{1}{\sqrt{2}} \\ \frac{1}{\sqrt{2}} & -\frac{1}{\sqrt{2}} \end{bmatrix} \begin{bmatrix} \phi^2 & 0 \\ 0 & 1/\phi^2 \end{bmatrix} \begin{bmatrix} \phi & 0 \\ 0 & 1/\phi \end{bmatrix}$

- 1 资料通常写成矩阵: n 个样本, 每个样本有 m 个量测值。
- 2 减去来自每个量测值的平均使得 A 的每个行中心化。
- 3 SVD 求出包含最多信息的资料的组合。
- 4 最大的奇异值 $\sigma_1 \leftrightarrow$ 最大的方差 $\leftrightarrow u_1$ 中最多的信息。

这个段落说明 SVD 在统计与资料分析的主要应用。我们的例子会来自人类遗传学与辨识与金融, 问题在于了解一个大型的资料(=量测值)矩阵。我们对 n 个样本的每一个样本量测 m 个变数, 资料矩阵 A_0 有 n 列 m 行。

从图形来看, A_0 的列是 $\mathbf{R}^m$ 的 n 个点, 在减去每一行的平均值之后得到 A , 这 n 个点通常会沿着一条直线聚集, 或是接近一个平面(或是其他 $\mathbf{R}^m$ 的低维子空间)。这些直线或平面或子空间为何?

让我从图形而不是数字开始, 当 $m = 2$ 个变数, 例如年纪与身高, 这 n 个点落在 $\mathbf{R}^2$ 的平面。减去平均年纪与平均身高使得资料中心化, 如果 n 个重置中心点沿着直线聚集, 线性代数要如何找出这条直线?



A 是 $2 \times n$ (大的零空间)
 AA^T 是 2×2 (小矩阵)
 $A^T A$ 是 $n \times n$ (大矩阵)
 两个奇异值 $\sigma_1 > \sigma_2 > 0$

图 7.2: A 中的资料点通常靠近 $\mathbf{R}^2$ 的直线或是 $\mathbf{R}^m$ 的子空间。

让我仔细一点来创建资料矩阵。从 A_0 的量测值开始, 找出每一行的平均值(平均数 mean) $\mu_1, \mu_2, \dots, \mu_m$, 从行 i 减去每个平均数 μ_i 使得资料中心化, 现在中心化矩阵 A 的每个行的平均值变成零, 所以图 7.2 的点 $(0, 0)$ 现在是 n 个点的真正中心。

样本协方差矩阵(covariance matrix)的定义是 $S = \frac{AA^T}{n-1}$

A 显示来自每个量测值与行平均值 μ_i 的距离 $a_{ij} - \mu_i$ 。
 $(AA^T)_{11}$ 与 $(AA^T)_{22}$ 显示距离平方的总和(样本方差 s_1^2, s_2^2)。
 $(AA^T)_{12}$ 显示样本协方差 $s_{12} = (A \text{ 的行 } 1) \cdot (A \text{ 的行 } 2)$ 。

方差是贯穿统计学的关键数字, 一个考试的平均成绩 $\mu = 85$ 告诉你这是一个相当不错的考试。一个 $s^2 = 25$ (标准差 $s = 5$) 的方差表示大部分的成绩都在 80 左右: 密集堆积。一个样本的方差 $s^2 = 225$ ($s = 15$) 表示分数是宽广分散。第十二章会说明方差。